

其中 $v, \omega_\theta, \omega_\varphi$ 分别为线速度、俯仰速度、偏航速度。假设线速度为常数，采样周期为 ΔT 。

量测值 $y_{i,k}$ 是由距离 $\gamma_i(k)$ ，俯仰角 $\theta_i(k)$ 和偏航角 $\varphi_i(k)$ 构成的向量，可通过传感器来获得：

$$y_{i,k} = [\gamma_i(k), \theta_i(k), \varphi_i(k)]^T. \quad (4.2.16)$$

进一步，需要建立类似量测方程(4.2.2)的形式来描述量测与位姿之间的关系。考虑到可以同时观测到 N 个特征点，这意味着将生成 N 个量测值 $y_{i,k}$ ($i = 1, 2, \dots, N$)：

$$\begin{bmatrix} \gamma_i(k) \\ \theta_i(k) \\ \varphi_i(k) \end{bmatrix} = \begin{bmatrix} \sqrt{(x(k) - x_i(k-1))^2 + (y(k) - y_i(k-1))^2 + (z(k) - z_i(k-1))^2} \\ \arctan\left(\frac{z(k) - z_i(k-1)}{\sqrt{(x(k) - x_i(k-1))^2 + (y(k) - y_i(k-1))^2}}\right) - \theta(k) \\ \arctan\left(\frac{y(k) - y_i(k-1)}{x(k) - x_i(k-1)}\right) - \varphi(k) \end{bmatrix} + \begin{bmatrix} v_\gamma(k) \\ v_\theta(k) \\ v_\varphi(k) \end{bmatrix}, \quad (4.2.17)$$

其中 $m_{i,k} = (x_i(k), y_i(k), z_i(k))$ 为 k 时刻特征点在世界坐标系中的位置信息，由下式得到

$$\begin{bmatrix} x_i(k) \\ y_i(k) \\ z_i(k) \end{bmatrix} = \begin{bmatrix} x(k) + \gamma_i(k) \cos(\theta_i(k) + \theta(k)) \cos(\varphi_i(k) + \varphi(k)) \\ y(k) + \gamma_i(k) \cos(\theta_i(k) + \theta(k)) \sin(\varphi_i(k) + \varphi(k)) \\ z(k) + \gamma_i(k) \sin(\theta_i(k) + \theta(k)) \end{bmatrix}. \quad (4.2.18)$$

4.3 非线性系统 ERSFF 算法设计

考虑 Hilbert 状态空间模型(4.2.1)和(4.2.2)，构建风险敏感性能指标如下：

$$\mu_k(\theta) = -\frac{2}{\theta} \log \left[\text{Exp} \left(-\frac{\theta}{2} C_k \right) \right], \quad (4.3.1)$$

$$C_k = \sum_{i=0}^k (\check{z}_{i|l} - Lx_i)^T (\check{z}_{i|l} - Lx_i), \quad (4.3.2)$$

其中 $\check{z}_{i|l}$ 被定义为量测 z_i 的估计值，容易看到 $E(C_k)$ 是 H_2 估计器的性能指标。

式(4.3.1)中的指数代价准则对应如下的极小化问题

$$\min_{\{\check{z}_{k|l}\}} \mu_k(\theta) = \min_{\{\check{z}_{k|l}\}} -\frac{2}{\theta} \log \left[\text{Exp} \left(-\frac{\theta}{2} C_k \right) \right], \quad (4.3.3)$$

其中参数 θ 称为风险敏感参数，任何使 $\mu_k(\theta)$ 极小化的滤波器都称为风险敏感滤波器。

由联合条件分布公式可得：

$$\begin{aligned} E\left(\exp\left(-\frac{\theta}{2}C_k\right)\right) &= \int \exp\left[-\frac{\theta}{2}C_k\right] p(x_0, w_0, \dots, w_k | y_0, \dots, y_k) dx_0 dw_0 \cdots dw_k \\ &\propto \int \exp\left[-\frac{\theta}{2}C_k\right] \exp\left[-\frac{1}{2}J_k\right] dx_0 dw_0 \cdots dw_k, \end{aligned} \quad (4.3.4)$$

$$J_k = x_0^T \mathcal{P}_0^{-1} x_0 + \sum_{i=0}^k w_i^T Q^{-1} w_i + \sum_{i=0}^k \varepsilon_i^T R^{-1} \varepsilon_i, \quad (4.3.5)$$

那么风险敏感评价准则可以写成

$$\theta > 0: \max_{\{\check{z}_{k|l}\}} \int \exp\left[-\frac{\theta}{2}C_k - \frac{1}{2}J_k\right] dx_0 dw_0 \cdots dw_k, \quad (4.3.6)$$

$$\theta < 0: \min_{\{\check{z}_{k|l}\}} \int \exp\left[-\frac{\theta}{2}C_k - \frac{1}{2}J_k\right] dx_0 dw_0 \cdots dw_k. \quad (4.3.7)$$

定义如下不定二次型

$$\begin{aligned} \tilde{J}_k &= J_k + \theta C_k \\ &= x_0^T \mathcal{P}_0^{-1} x_0 + \sum_{i=0}^k w_i^T Q^{-1} w_i + \sum_{i=0}^k \varepsilon_i^T R^{-1} \varepsilon_i + \theta \sum_{i=0}^k (\check{z}_{k|l} - Lx_i)^T (\check{z}_{k|l} - Lx_i). \end{aligned} \quad (4.3.8)$$

为了处理极值，必须确保式(4.3.6)和(4.3.7)的积分是有限的。下面来证明积分的存在性。

引理 4.1(有限条件引理). 积分

$$\int \exp\left[-\frac{1}{2}\tilde{J}_k\right] dx_0 dw_0 \cdots dw_k$$

是有限的当且仅当 \tilde{J}_k 在 $\{x_0, w_0, \dots, w_k\}$ 上有最小值。在这种情况下，它正比于

$$\exp\left[-\frac{1}{2}\min_{x_0, w} \tilde{J}_k\right].$$

上述引理将风险敏感问题简化为寻找二阶标量形式的极小值问题。更准确地说，评价准则变成了

$$\theta > 0: \max_{\{\check{z}_{k|l}\}} \left\{ \min_{x_0, w} \tilde{J}_k \right\}, \quad (4.3.9)$$

$$\theta < 0: \min_{\{\check{z}_{k|l}\}} \left\{ \min_{x_0, w} \tilde{J}_k \right\}. \quad (4.3.10)$$

为了解决上述问题，引入如下 Krein 状态空间模型

$$x_{k+1} = f(x_k, u_k) + w_k, \quad (4.3.11)$$

$$\begin{bmatrix} y_k \\ \check{z}_{k|k} \end{bmatrix} = \begin{bmatrix} h(x_k) \\ L_k x_k \end{bmatrix} + v_k, \quad (4.3.12)$$

其中 $\check{z}_{k|k}$ 是待估计状态的任意线性组合，状态初值及噪声参数信息如下：

$$\left\langle \begin{bmatrix} \mathbf{x}_0 \\ \mathbf{w}_i \\ \mathbf{v}_i \end{bmatrix}, \begin{bmatrix} \mathbf{x}_0 \\ \mathbf{w}_j \\ \mathbf{v}_j \end{bmatrix} \right\rangle = \begin{bmatrix} \mathcal{P}_0 & 0 & 0 \\ 0 & Q\delta_{ij} & 0 \\ 0 & 0 & \begin{bmatrix} R & 0 \\ 0 & \theta^{-1}I \end{bmatrix} \delta_{ij} \end{bmatrix}. \quad (4.3.13)$$

注意，这里用粗体字母表示 Krein 状态空间下的元素，欧几里得空间中的元素用普通字母表示。

下面给出一个有用的矩阵逆引理，它可以简化后续定理 4.1 的证明。

引理 4.2(矩阵逆引理). 假设 C 是非奇异的，那么

$$(A + BCD)^{-1} = A^{-1} - A^{-1}B(C^{-1} + DA^{-1}B)^{-1}DA^{-1}. \quad (4.3.14)$$

定理 4.1. 给定系统(4.3.11)-(4.3.12)，假设 4.1-4.2 成立。对于给定 $\theta > 0$ 的后验风险敏感滤波器，风险敏感估计问题总是有一个解。对于给定 $\theta < 0$ 的风险敏感滤波器，存在一个解的充要条件为

$$\begin{bmatrix} R & 0 \\ 0 & \theta^{-1}I \end{bmatrix} \text{ 和 } R_{e,k} = \begin{bmatrix} R & 0 \\ 0 & \theta^{-1}I \end{bmatrix} + \begin{bmatrix} H_k \\ L_k \end{bmatrix} P_k \begin{bmatrix} H_k^T & L_k^T \end{bmatrix}$$

对于所有 $i = 0, 1, \dots, n$ 有相同的惯性，其中 $P_0 = \mathcal{P}_0$ ，且

$$P_{k+1} = F_k P_k F_k^T + Q - F_k P_k \begin{bmatrix} H_k^T & L_k^T \end{bmatrix} R_{e,k}^{-1} \begin{bmatrix} H_k \\ L_k \end{bmatrix} P_k F_k^T, \quad (4.3.15)$$

$$\boldsymbol{\varepsilon}_k = \begin{bmatrix} \mathbf{y}_k - h(\hat{\mathbf{x}}_k^-) \\ \check{\mathbf{z}}_{k|k} - \hat{\mathbf{z}}_{k|k-1} \end{bmatrix}. \quad (4.3.16)$$

在这两种情况下，最优风险敏感滤波器可由如下公式给出

$$\check{\mathbf{z}}_{k|k} = L_k \hat{\mathbf{x}}_k^+,$$

$$\hat{\mathbf{x}}_{k+1}^- = f(\hat{\mathbf{x}}_k^+, u_k),$$

$$\hat{\mathbf{x}}_{k+1}^+ = F_k \hat{\mathbf{x}}_k^+ + K_{k+1}(\mathbf{y}_{k+1} - h(\hat{\mathbf{x}}_{k+1}^-)),$$

$$K_{k+1} = P_{k+1} H_{k+1}^T (R + H_{k+1} P_{k+1} H_{k+1}^T)^{-1}.$$

假设有局部滤波器 $\hat{\mathbf{x}}_{k+1,1}^+, \hat{\mathbf{x}}_{k+1,2}^+, \dots, \hat{\mathbf{x}}_{k+1,m}^+$ ，加权融合估计量 $\hat{\mathbf{x}}_{fusion}(k)$ 可由标量加权融合算法[107]得到：

$$\hat{\mathbf{x}}_{fusion}(k) = \sum_{i=1}^m \omega_i(k) \hat{\mathbf{x}}_{k+1,i}^+,$$

其中最优加权系数向量 $\boldsymbol{\omega}(k) = [\omega_1(k), \omega_2(k), \dots, \omega_m(k)]$ 为

$$\boldsymbol{\omega}(k) = \frac{e^T P_{tr}^{-1}(k)}{e^T P_{tr}^{-1}(k) e},$$

其中

$$P_{tr}(k) = \begin{bmatrix} tr P_{11}(k) & \cdots & tr P_{1m}(k) \\ \vdots & & \vdots \\ tr P_{m1}(k) & \cdots & tr P_{mm}(k) \end{bmatrix}, e = \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix}.$$

证明：回顾第 4.2.1 节中 EKF 的推导，非线性系统(4.3.11)和(4.3.12)可以被线性化为

$$\mathbf{x}_{k+1} = F_k \mathbf{x}_k + \tilde{\mathbf{u}}_{k,1} + \mathbf{w}_k, \quad (4.3.17)$$

$$\begin{bmatrix} \mathbf{y}_k \\ \check{\mathbf{z}}_{k|l} \end{bmatrix} = \begin{bmatrix} H_k \mathbf{x}_k + \tilde{\mathbf{u}}_{k,2} \\ L_k \mathbf{x}_k \end{bmatrix} + \mathbf{v}_k. \quad (4.3.18)$$

对于 $\theta > 0$ ，解总是存在的，因为 $\begin{bmatrix} R & 0 \\ 0 & \theta^{-1}I \end{bmatrix} > 0$ ，状态空间模型简化为通常的希尔伯特空间设置，对这种情况不进行讨论。

对于 $\theta < 0$ ，首先需要证明 \tilde{J}_k 是否存在最小值。在解的存在性得到证明后，选择 $\check{\mathbf{z}}_{k|k}$ ，使得 \tilde{J}_k 的最小值是正定的。

$$\begin{aligned} \tilde{J}_k &= \sum_{i=0}^k \boldsymbol{\varepsilon}_i^T R_{e,k}^{-1} \boldsymbol{\varepsilon}_i \\ &= \sum_{i=0}^k \begin{bmatrix} \mathbf{y}_k - h(\hat{\mathbf{x}}_k^-) \\ \check{\mathbf{z}}_{k|k} - \hat{\mathbf{z}}_{k|k-1} \end{bmatrix}^T \begin{bmatrix} R + H_k P_k H_k^T & H_k P_k L_k^T \\ L_k P_k H_k^T & \theta^{-1}I + L_k P_k L_k^T \end{bmatrix}^{-1} \begin{bmatrix} \mathbf{y}_k - h(\hat{\mathbf{x}}_k^-) \\ \check{\mathbf{z}}_{k|k} - \hat{\mathbf{z}}_{k|k-1} \end{bmatrix} \\ &= \sum_{i=0}^k \left\{ \begin{bmatrix} \mathbf{y}_k - h(\hat{\mathbf{x}}_k^-) \\ \check{\mathbf{z}}_{k|k} - \hat{\mathbf{z}}_{k|k} \end{bmatrix}^T \right. \\ &\quad \times \begin{bmatrix} R + H_k P_k H_k^T & \\ & \theta^{-1}I + L_k \left(P_k - P_k H_k^T (R + H_k P_k H_k^T)^{-1} H_k P_k \right) L_k^T \end{bmatrix}^{-1} \\ &\quad \left. \times \begin{bmatrix} \mathbf{y}_k - h(\hat{\mathbf{x}}_k^-) \\ \check{\mathbf{z}}_{k|k} - \hat{\mathbf{z}}_{k|k} \end{bmatrix} \right\}, \end{aligned} \quad (4.3.19)$$

其中

$$\begin{bmatrix} \mathbf{y}_k - h(\hat{\mathbf{x}}_k^-) \\ \check{\mathbf{z}}_{k|k} - \hat{\mathbf{z}}_{k|k} \end{bmatrix} \triangleq \begin{bmatrix} I & \\ -L_k P_k H_k^T (R + H_k P_k H_k^T)^{-1} & I \end{bmatrix} \begin{bmatrix} \mathbf{y}_k - h(\hat{\mathbf{x}}_k^-) \\ \check{\mathbf{z}}_{k|k} - \hat{\mathbf{z}}_{k|k-1} \end{bmatrix}. \quad (4.3.20)$$

利用引理 4.2，可将式(4.3.19)改写为：

$$\sum_{i=0}^k \begin{bmatrix} \mathbf{y}_k - h(\hat{\mathbf{x}}_k^-) \\ \check{\mathbf{z}}_{k|k} - \hat{\mathbf{z}}_{k|k} \end{bmatrix}^T \begin{bmatrix} R + H_k P_k H_k^T & \\ & \theta^{-1}I + L_k (P_k^{-1} + H_k^T H_k)^{-1} L_k^T \end{bmatrix}^{-1} \begin{bmatrix} \mathbf{y}_k - h(\hat{\mathbf{x}}_k^-) \\ \check{\mathbf{z}}_{k|k} - \hat{\mathbf{z}}_{k|k} \end{bmatrix}. \quad (4.3.21)$$

注意， $\hat{\mathbf{z}}_{k|k-1}$ 是 $\check{\mathbf{z}}_{k|k}$ 在 Krein 空间下的线性流形 $\mathcal{L} \{ \{\mathbf{y}_i\}_{i=0}^{k-1}, \{\check{\mathbf{z}}_{i|i}\}_{i=0}^{k-1} \}$ 上的投影，因此， $\hat{\mathbf{z}}_{k|k-1}$ 是一个关于 $\{\mathbf{y}_i\}_{i=0}^{k-1}$ 的线性函数。进一步， $\hat{\mathbf{z}}_{k|k}$ 是 $\check{\mathbf{z}}_{k|k}$ 在 Krein 空间下的线性流形 $\mathcal{L} \{ \{\mathbf{y}_i\}_{i=0}^k, \{\check{\mathbf{z}}_{i|i}\}_{i=0}^{k-1} \}$ 上的投影，因此 $\hat{\mathbf{z}}_{k|k}$ 是关于 $\{\mathbf{y}_i\}_{i=0}^k$ 的线性函数。

根据文献[105]的惯性最小条件引理和 R_y 的惯性引理，可以得到如下结论。如果 $\mathcal{P}_0 > 0$ 且 $Q > 0$ ，则二次型 J_k 的稳定点为

$$J_k = \begin{bmatrix} \mathbf{y}_k \\ \check{\mathbf{z}}_{k|k} \end{bmatrix}^T R_{y,k}^{-1} \begin{bmatrix} \mathbf{y}_k \\ \check{\mathbf{z}}_{k|k} \end{bmatrix},$$

该稳定点为最小值的充分必要条件是 $R_{y,k}$ 和 $\begin{bmatrix} R & 0 \\ 0 & \theta^{-1}I \end{bmatrix}$ 具有相同的惯性，其中

$$R_{y,k} = \left\langle \begin{bmatrix} y_k \\ \check{z}_{k|k} \end{bmatrix}, \begin{bmatrix} y_k \\ \check{z}_{k|k} \end{bmatrix} \right\rangle, \quad (4.3.22)$$

y 的 Gramian 行列式 $R_{y,k}$ 和新息的 Gramian 行列式 $R_{e,k}$ 有相同的惯性。 $R_{y,k}$ 的强正则性意味着 $R_{e,k}$ 的非奇异性。假设 $R_{y,k} > 0$ ，当且仅当

$$R_{e,k} > 0.$$

由上述引理可知，如果存在一个风险敏感估计量，当且仅当 $\begin{bmatrix} R & 0 \\ 0 & \theta^{-1}I \end{bmatrix}$ 和 $R_{e,k}$ 必须具有相同的惯性。容易看到

$$R + H_k P_k H_k^T > 0$$

和

$$\theta^{-1}I + L_k(P_k^{-1} + H_k^T H_k)^{-1} L_k^T < 0.$$

此外，由于稳定点 \tilde{J}_k 是正定的，必须确保

$$\begin{aligned} & \sum_{i=0}^k [y_k - h(\hat{x}_k^-)]^T (R + H_k P_k H_k^T)^{-1} [y_k - h(\hat{x}_k^-)] \\ & + \sum_{i=0}^k [\check{z}_{k|k} - \hat{z}_{k|k}]^T [\theta^{-1}I + L_k(P_k^{-1} + H_k^T H_k)^{-1} L_k^T]^{-1} [\check{z}_{k|k} - \hat{z}_{k|k}] > 0. \end{aligned} \quad (4.3.23)$$

显然，可以选择令

$$\check{z}_{k|k} = \hat{z}_{k|k} = L_k \hat{x}_k^+,$$

其中 \hat{x}_k^+ 由 Krein 中的 x_k 在线性流形 $\mathcal{L}\left\{\{y_i\}_{i=0}^k, \{\check{z}_{i|i}\}_{i=0}^{k-1}\right\}$ 上的投影给出。现在可以在状态空间模型(4.3.17)和(4.3.18)上进行 Kerin 空间 KF 的递归计算，求解最优状态滤波 \hat{x}_k^+ ，有

$$\hat{x}_{k+1}^+ = \hat{x}_{k+1}^- + P_{k+1} [H_{k+1}^T \quad L_{k+1}^T] R_{e,k}^{-1} \epsilon_k. \quad (4.3.24)$$

选择 $\check{z}_{k+1|k+1} = \hat{z}_{k+1|k+1}$ 且根据矩阵逆引理，可以将上面的式子重写为如下公式

$$\begin{aligned} \hat{x}_{k+1}^+ &= \hat{x}_{k+1}^- + P_{k+1} [H_{k+1}^T \quad L_{k+1}^T] \begin{bmatrix} I & -(R + H_{k+1} P_{k+1} H_{k+1}^T)^{-1} H_{k+1} P_{k+1} L_{k+1}^T \\ & I \end{bmatrix} \\ &\quad \times \begin{bmatrix} R + H_k P_k H_k^T & \\ & \theta^{-1}I + L_k(P_k^{-1} + H_k^T H_k)^{-1} L_k^T \end{bmatrix}^{-1} \begin{bmatrix} y_{k+1} - h(\hat{x}_{k+1}^-) \\ \check{z}_{k+1|k+1} - \hat{z}_{k+1|k+1} \end{bmatrix} \\ &= \hat{x}_{k+1}^- + P_{k+1} H_{k+1}^T (R + H_{k+1} P_{k+1} H_{k+1}^T)^{-1} [y_{k+1} - h(\hat{x}_{k+1}^-)]. \end{aligned} \quad (4.3.25)$$

标量加权融合算法在[107]中得到了详细的证明。

定理 4.1 得证。